

# Regresja Logistyczna

Dominik Jur

25 marca 2025

# Konwencje notacyjne

W prezentacji stosujemy następujące oznaczenia:

- Wektory cech oznaczane są jako  $x^{(i)}$  (dla  $i$ -tej próbki) lub  $x$  (dla ogólnego przypadku)
- Etykiety klas:  $y^{(i)} \in \{0, 1\}$  (dla próbek) lub  $y$  (ogólnie)
- Przewidywania modelu:  $\hat{y}(x^{(i)})$  lub  $\hat{y}^{(i)}$
- Parametry modelu:  $\theta = [\theta_0, \theta_1, \dots, \theta_n]^T$
- $\theta_0$  to wyraz wolny (bias)
- Funkcja sigmoidalna:  $\sigma(z) = \frac{1}{1+e^{-z}}$
- $n$  - liczba próbek w zbiorze danych
- $m$  - liczba cech (wymiarowość wektorów  $x$ )

Dodatkowe konwencje:

- Indeksy górne w nawiasach ( $i$ ) odnoszą się do numeru próbki
- Indeksy dolne (np.  $x_j$ ) odnoszą się do konkretnej cechy
- Operacje na wektorach domyślnie traktujemy jako operacje kolumnowe

# Metoda Gradientu Prostego

---

**Algorithm 1** Algorytm gradientu prostego

---

```
1: Inicjalizujemy wektor parametrów  $\theta$ , stałą uczenia  $\eta$  i tolerancję  $\varepsilon$ .
2: while true do
3:   Oblicz gradient funkcji kosztu  $\nabla J(\theta)$ .
4:   if  $\|\nabla J(\theta)\| < \varepsilon$  then
5:     przerwij pętlę
6:   end if
7:   Zaktualizuj parametry:  $\theta \leftarrow \theta - \eta \nabla J(\theta)$ 
8: end while
```

---

Gdzie  $\|\nabla J(\theta)\|$  to norma gradientu  $J(\theta)$ .

# Regresja Logistyczna

Funkcja hipotezy liniowej dla wektora cech  $x$  dana jest wzorem:

$$h_{\theta}(x) = \theta_0 + \sum_{i=1}^n \theta_i x_i.$$

gdzie  $\theta$  to wektor parametrów, a  $\theta_0$  jest wyrazem wolnym. Wynik regresji logistycznej definiuje się jako:

$$\text{RegresjaLogistyczna}(x) = \sigma(h_{\theta}(x)) = \frac{1}{1 + e^{-h_{\theta}(x)}},$$

gdzie  $x$  oznacza wektor cech wejściowych.

## Kwestia metryk do ucznia modelu

Regresja logistyczna przewiduje prawdopodobieństwa ( $\hat{y} \in [0, 1]$ ), podczas gdy MSE jest typowo używany w zadaniach regresji liniowej (gdzie  $y \in \mathbb{R}$ ).

Główne powody wyboru Log Loss:

MSE zakłada liniową zależność błędu od parametrów, co prowadzi do **niewypukłej funkcji kosztu** dla regresji logistycznej:

$$J_{\text{MSE}}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}(x^{(i)}))^2.$$

Powoduje to wiele minimów lokalnych, utrudniając optymalizację.

Log Loss jest wypukła i nie ma problemów tej natury:

$$J_{\text{Log}}(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)].$$

# Błąd logistyczny dla pojedynczego wektora cech

Funkcja błędu logistycznego dla pojedynczego wektora cech  $x^{(i)}$ :

$$J(\theta) = -y^{(i)} \log(\hat{y}(x^{(i)})) - (1 - y^{(i)}) \log(1 - \hat{y}(x^{(i)})) .$$

Jako, że  $\forall_i y^{(i)} \in \{0, 1\}$ , możemy zapisać błąd logistyczny jako funkcję kłamrową:

$$J(\theta) = \begin{cases} -\log(\hat{y}(x^{(i)})) , & \text{dla } y^{(i)} = 1, \\ -\log(1 - \hat{y}(x^{(i)})) , & \text{dla } y^{(i)} = 0. \end{cases}$$

## Pochodna funkcji kosztu po parametrze $\theta_j$

Dla funkcji hipotezy w regresji logistycznej:

$$\hat{y}^{(i)} = \sigma(z^{(i)}) = \frac{1}{1 + \exp(-z^{(i)})}, \quad \text{gdzie } z^{(i)} = h_{\theta}(x^{(i)})$$

Pochodna po parametrze  $\theta_j$  jest zadana wzorem:

$$\begin{aligned} \frac{\partial}{\partial \theta_j} \hat{y}^{(i)} &= \frac{\partial}{\partial \theta_j} \frac{1}{1 + \exp(-z^{(i)})} = \frac{\partial}{\partial z^{(i)}} \frac{1}{1 + \exp(-z^{(i)})} \cdot \frac{\partial}{\partial \theta_j} z^{(i)} \\ &= \frac{1}{[1 + \exp(-z^{(i)})]^2} \exp(-z^{(i)}) \cdot \frac{\partial}{\partial \theta_j} z^{(i)} \\ &= \frac{1}{1 + \exp(-z^{(i)})} \left[ 1 - \frac{1}{1 + \exp(-z^{(i)})} \right] \frac{\partial}{\partial \theta_j} z^{(i)} \\ &= \hat{y}^{(i)} [1 - \hat{y}^{(i)}] \frac{\partial}{\partial \theta_j} z^{(i)}. \end{aligned}$$

## Pochodna funkcji kosztu po parametrze $\theta_j$

Pochodna funkcji kosztu po parametrze  $\theta_j$  dla pojedynczego wektora cech:

$$\begin{aligned}\frac{\partial}{\partial \theta_j} J(\theta) &= - \left[ y^{(i)} \frac{\partial}{\partial \theta_j} \log \hat{y}^{(i)} + (1 - y^{(i)}) \frac{\partial}{\partial \theta_j} \log(1 - \hat{y}^{(i)}) \right] \\&= - \left[ \frac{y^{(i)}}{\hat{y}^{(i)}} - \frac{1 - y^{(i)}}{1 - \hat{y}^{(i)}} \right] \frac{\partial \hat{y}^{(i)}}{\partial \theta_j} \\&= - \left[ \frac{y^{(i)}(1 - \hat{y}^{(i)}) - (1 - y^{(i)})\hat{y}^{(i)}}{\hat{y}^{(i)}(1 - \hat{y}^{(i)})} \right] \hat{y}^{(i)}(1 - \hat{y}^{(i)}) \frac{\partial z^{(i)}}{\partial \theta_j} \\&= - \left[ y^{(i)} - y^{(i)}\hat{y}^{(i)} - \hat{y}^{(i)} + y^{(i)}\hat{y}^{(i)} \right] x_j^{(i)} \\&= - \left[ y^{(i)} - \hat{y}^{(i)} \right] x_j^{(i)}.\end{aligned}$$

Ostatecznie otrzymujemy wzór:

$$\frac{\partial}{\partial \theta_j} J(\theta) = (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$



# Gradient funkcji kosztu

Zatem całkowita wartość pochodnej  $J(\theta)$  po  $\theta_j$  jest postaci:

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$

Gradient jest postaci:

$$\nabla J(\theta) = \begin{bmatrix} \frac{\partial}{\partial \theta_0} \\ \frac{\partial}{\partial \theta_1} \\ \vdots \\ \frac{\partial}{\partial \theta_m} \end{bmatrix}.$$

Kosztując z tak policzonego gradientu możemy nauczyć model regresji liniowej stosując metodę gradientu prostego.