

Regresja Liniowa

KNSM "Gauss"

Lato 2025

Ogólna postać modelu liniowego

Model liniowy przewiduje wartość poprzez obliczenie ważonej sumy cech wejściowych oraz składnika wolnego:

$$\hat{y}^{(i)} = \theta_0 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}.$$

- ▶ $\hat{y}^{(i)}$: Przewidywana wartość dla i -tej instancji.
- ▶ n : Liczba cech.
- ▶ $x_j^{(i)}$: Wartość j -tej cechy dla i -tej instancji.
- ▶ θ_j : Parametry modelu (w tym składnik wolny θ_0 oraz wagi $\theta_1, \theta_2, \dots, \theta_n$).
- ▶ Zakładamy, że $\forall_{j=1,2,\dots,m} x_0^{(j)} = 1$.

Postać wektorowa

Przewidywanie dla i -tej instancji można zapisać w zwartej postaci wektorowej:

$$\hat{y}^{(i)} = \theta \cdot x^{(i)}.$$

- ▶ θ : Wektor parametrów (składnik wolny + wagi).
- ▶ $x^{(i)}$: Wektor cech dla i -tej instancji (z $x_0^{(i)} = 1$ dla składnika wolnego).
- ▶ $\theta \cdot x^{(i)}$: Iloczyn skalarny wektorów θ i $x^{(i)}$.

Notacja macierzowa

Jeśli θ jest wektorem i X jest macierzą:

$$\hat{y} = X\theta.$$

- ▶ \hat{y} : Wektor przewidywań dla wszystkich instancji.
- ▶ X : Macierz cech (każdy wiersz odpowiada instancji).
- ▶ θ : Wektor parametrów (składnik wolny + wagi).

Uczenie modelu

Uczenie polega na znalezieniu parametrów θ , które minimalizują błąd predykcji.

- ▶ Miara wydajności: **Błąd Średniokwadratowy (MSE)**

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2.$$

- ▶ m : Liczba próbek.
- ▶ $\hat{y}^{(i)}$: Przewidywanie dla i -tej instancji.
- ▶ $y^{(i)}$: Rzeczywista wartość dla i -tej instancji.
- ▶ Minimalizowanie MSE minimalizuje również RMSE.

Minimalizacja MSE

Aby znaleźć optymalne parametry $\hat{\theta}$, minimalizujemy MSE:

- ▶ Używamy **Równania Normalnego** (rozwiązanie analityczne):

$$\hat{\theta} = (X^T X)^{-1} X^T y.$$

- ▶ Używanie algorytmów optymalizacji (np. gradientu prostego) jest tutaj nieoptymalne, wróć analityczny jest szybszy.

Wyprowadzenie Równania Normalnego

Minimalizujemy MSE w postaci macierzowej:

$$\text{MSE} = \frac{1}{m}(X\theta - y)^T(X\theta - y).$$

Rozwijamy wyrażenie:

$$\text{MSE} = \frac{1}{m} \left[\theta^T X^T X \theta - 2\theta^T X^T y + y^T y \right].$$

Pochodna względem θ :

$$\frac{\partial \text{MSE}}{\partial \theta} = \frac{2}{m}(X^T X \theta - X^T y) = 0.$$

Rozwiązanie dla θ :

$$X^T X \theta = X^T y \implies \hat{\theta} = (X^T X)^{-1} X^T y. \quad \square$$